

Z-score e Binomial Distribution
Sample distribution and sampling
distribution TLC p-value

Jupyter e git

Fazer cada atividade no Jupyter (Collab) e use o Git para gerenciar o seu projeto. Sem esse requisito sua tarefa não será avaliada. Poste apenas os links.

Organize seu Jupyter de acordo com essa apresentação. Se a organização estiver confusa, a atividade perderá pontos.

Para cada parte da atividade, colocar o comando do problema e fazer uma introdução com figuras, equações e texto contextualizando o problema.

Parte 1

Z-score e Binomial Distribution

Material

[Part 1 - Histograms](#)

[Part 2 - The Main Ideas behind
Probability Distributions.pptx](#)

[Part 3 - The Normal
Distribution.pptx](#)

[Part 3.2 - Binomial
distributions.pptx](#)

A

Busque um dataset e faça histogramas de duas features para cada classe no dataset, conforme procedimento mostrado em sala. Faça dois conjuntos de histogramas com tamanhos de bins diferentes. Discuta os histogramas do ponto de vista de classificação usando aprendizado de máquina e também discuta os tamanhos dos bins usados.

Não esqueça do contexto sobre o dataset usado, com a explicação sobre ele, suas classes e features.

B

Considerando o primeiro trabalho, defina um experimento em que dados são coletados de uma variável de interesse do seu trabalho. Produza dados artificiais, plote o histograma e a distribuição que aproxime os dados. Em seguida, defina estudos como o exemplo da pizza explicado em sala, sempre partido da versão não padronizada e depois os cálculos na versão padronizada. Sempre considerando o contexto do seu primeiro trabalho.

Use uma função de Python e uma tabela para obter os valores de probabilidade.

C

$$P_x = \binom{n}{x} p^x q^{n-x}$$

P = binomial probability

x = number of times for a specific outcome within n trials

$\binom{n}{x}$ = number of combinations

p = probability of success on a single trial

q = probability of failure on a single trial

n = number of trials

Para $s = 0.80$, reproduza a mesma simulação do slide anterior. Faça o cálculo explicitamente, usando a equação. Compare os resultados. Mostre o histograma também para as 10 primeiras amostras, conforme exemplo dos próximos slides.


$s = 0.95$

✓	✓	✓	✓	✓	✓	✓	✓	✗	✓
0.55	0.72	0.60	0.54	0.42	0.65	0.44	0.89	0.96	0.38


9



$s = 0.95$




$$s = 0.95$$




$s = 0.95$

✓ ✓ ✓ ✓ ✓ ✓ ✓ ✓ ✓ ✓
0.19 0.10 0.12 0.36 0.00 0.42 0.66 0.40 0.09 0.06

10




$$s = 0.95$$




$s = 0.95$

✓	✓	✗	✓	✓	✓	✓	✓	✗	✓
0.28	0.17	0.97	0.15	0.81	0.59	0.57	0.51	0.97	0.36

8




$s = 0.95$



$s = 0.95$

✓ ✓ ✓ ✓ ✓ ✓ ✓ ✓ ✓ ✓
0.43 0.04 0.77 0.50 0.79 0.75 0.79 0.30 0.80 0.55


10



$s = 0.95$

✓	✓	✗	✓	✓	✓	✓	✓	✓	✓
0.31	0.56	0.98	0.40	0.67	0.40	0.77	0.53	0.24	0.27


9



$s = 0.95$

✓ ✓ ✓ ✓ ✓ ✓ ✓ ✓ ✓ ✓
0.70 0.03 0.87 0.44 0.50 0.54 0.65 0.34 0.10 0.32

10



Parte 2

Sample distribution and sampling distribution
TLC
p-value

A: *sample distribution* and *sampling distribution*

A partir do que foi feito na Atividade 2 “Considerando o primeiro trabalho, defina um experimento em que dados são coletados de uma variável de interesse do seu trabalho”, crie uma população artificial dessa variável com uma distribuição Gaussiana e demonstre *sample distribution* and *sampling distribution*. Faça avaliações de probabilidade de possíveis eventos.

[Part 6 - Calculating the Mean, Variance and Standard Deviation.pptx](#)

[Part 9 - Sampling from a Distribution.pptx](#)

B: *TLC*

Aplique o TLC a função de distribuição gama e avalie quatro diferentes tamanhos de amostra, começando em 10.

[Part 4 - The Central Limit Theorem.pptx](#)

C: *p-value*

Faça um programa que mostra o passo a passo para calcular o p-value do evento abaixo. Coloque figuras para cada passo.




[Part 7_2 - How to calculate p-values](#)

[Part 7_1 - What are p-values?.pptx](#)

D: *p*-value

Crie duas Gaussianas como mostrado abaixo (é só variar a média). Sorteie 100 sequências de três valores na azul e para cada sequência calcule o *p*-value a partir da vermelha. Veja a seta vermelha que indica a partir de qual amostra é calculado *p*-value. Calcule a taxa de falso negativos (*p*-value acima de 5%).



Taxa de falsos negativos: desde que se adote como hipótese nula a distribuição vermelha e que a distribuição azul represente uma situação alternativa verdadeira.

Interpretação estatística

- Hipótese nula (H_0): os dados vêm da distribuição **vermelha**.
- Hipótese alternativa (H_1): os dados vêm de outra distribuição — no caso, a **azul**.
- Como os dados realmente vêm da **azul**, a **hipótese nula é falsa**.
- Quando o **p-valor** > 0.05 , **não rejeitamos** a hipótese nula.
- **Portanto, estamos cometendo um falso negativo (erro tipo II):** a hipótese nula é falsa, mas não a rejeitamos.