



DISCIPLINA: Tópicos especiais (68): Introdução à Estatística e LLMs

CÓDIGO: EN05XXX

Carga Horária:		Teórica		Prática		Presen	Dist		Total
	Semanal								
	Período	68							68

PROFESSOR (A): Claudomiro de Souza de Sales Junior

I OBJETIVOS:

Apresentar os conceitos introdutórios de estatística, como distribuições, p-value e testes estatísticos. O curso abordará também conceitos básicos de aprendizado de máquina, como matriz de confusão, métricas, ROC, e aprendizado supervisionado, por reforço e não supervisionado, incluindo técnicas específicas para regressão, classificação e clusterização. Além disso, serão introduzidos conceitos de redes neurais artificiais e sua evolução, culminando no estudo de Modelos de Linguagem de Grande Escala (LLMs), como a série GPT, explorando o funcionamento, o treinamento e as capacidades de modelos pré-treinados. Ao final desta disciplina, o aluno será capaz de compreender o funcionamento de redes neurais e LLMs, além de estar ciente dos avanços recentes na área e das implicações éticas do uso desses modelos.

II PERFIL, COMPETÊNCIAS E HABILIDADES:

Essa disciplina tem o objetivo de ensinar conceitos básicos de estatística, aprendizado de máquina e redes neurais para o entendimento de LLMs. Se você já possui conhecimentos intermediários de aprendizado de máquina e redes neurais, talvez essa disciplina não seja adequada para você. Ao longo da disciplina você poderá ficar entediado mas cheio de atividades para fazer. Fica o aviso.

Você precisará ter habilidades para construir sistemas computacionais, saber lidar com diferentes repositórios e integrar esses repositórios às suas aplicações. Será necessário ter autonomia no desenvolvimento do seu código e gostar de manipular código e resolver problemas.

A disciplina envolve matemática: vetores, derivadas, integrais e, principalmente, multiplicação de matrizes. No entanto, nessa disciplina não vamos passar meses resolvendo integrais e derivadas para entender um conceito, para no final vocês continuarem a não entender integrais e derivadas, e menos ainda o conceito inicial. Mas a matemática é a melhor forma de explicar um conceito e computação é matemática. Então se você não gosta de matemática, talvez essa disciplina não seja adequada para você.

IV CONTEÚDO PROGRAMÁTICO:

1 Introdução Geral

- 1.1 – Motivação.
- 1.2 – A história das redes neurais.
 - O neurônio de McCulloch-Pitts (MCP) e o perceptron de Frank Rosenblatt (1958).
- 1.3 – História de LLMs: 30 anos de história, como a IA aprendeu a falar.

2 Introdução à estatística e probabilidade

- 2.1 – Histogramas.
- 2.2 – Distribuições de probabilidade.
- 2.3 – A distribuição normal.
- 2.4 – Teorema do limite central.
- 2.5 – População e estimação de parâmetros.
- 2.6 – p-values, o que é e como interpretar?
- 2.7 – Teste de hipóteses e hipótese nula.
- 2.8 – Correlação e covariância.
- 2.9 – Valores esperados, probabilidade condicional e teorema de Bayes.
- 2.10 – Básico de álgebra linear: vetores, transformações lineares, multiplicação de matrizes, produto escalar e vetorial, e autovalores e autovetores

3 Conceitos básicos de aprendizado de máquina

- 3.1 – Exemplos simples de aprendizado de máquina: dados de treino e teste.
- 3.2 – Matriz de confusão, sensibilidade, especificidade, precisão, acurácia e F1.
- 3.3 – Validação cruzada.
- 3.4 – Bias e variance em métodos de aprendizado de máquina.
- 3.5 – ROC e AUC.
- 3.6 – Entropia para ciência de dados.
- 3.7 – Alguns exemplos de algoritmos de aprendizado de máquina: regressão linear e logística, KNN e Naive Bayes.
- 3.8 – Convolução: entendendo kernels (filtros) e como eles interagem com as imagens.

4 Redes neurais

- 4.1 – O neurônio de McCulloch-Pitts (MPC) e o perceptron de Frank Rosenblatt (1958).
- 4.2 – Tentando dar transparência para a caixa preta: redes neurais como *squiggles machines*.
- 4.3 – A regra da cadeia.
- 4.4 – *Gradient Descent* (Descida do Gradiente) e *Stochastic Gradient Descent* (Descida do Gradiente Estocástico).
- 4.5 – Backpropagation: o mais importante algoritmo de aprendizado de máquina.
 - Demonstrando o backpropagation com a otimização de 3 parâmetros simultaneamente.
 - Aplicando para toda a rede.
- 4.6 – Funções de ativação.
 - A função de ativação ReLU.
- 4.7 – Redes neurais com múltiplas entradas e saídas.
- 4.8 – ArgMax e SoftMax.
- 4.9 – Tipos de redes neurais: CNN, RNN e LSTM.

5 Aprendizado por reforço

- 5.1 – Agente, ambiente, recompensa e política.
- 5.2 – State value function and action-value function.
- 5.2 – Bellman equations, dynamic programming e generalized policy iteration.
- 5.3 – Monte Carlo and off-policy methods.
- 5.4 – Temporal Difference Learning (including Q-Learning).
- 5.5 – Deep reinforcement learning: Deep Q-Networks (DQN) and policy Gradient methods.

6	LLMs
6.1	– Word Embedding e Word2Vec.
6.2	– Redes Neurais Encoder-Decoder Sequence-to-Sequence (seq2seq).
6.3	– Sequence to Sequence (seq2seq) e Attention.
6.4	– Redes Neurais Transformer. - "Attention Is All You Need" by Vaswani et al. - Estudo de caso: ChatGPT 3 e quantidade de parâmetros.
6.5	– Decoder-Only Transformers.
6.6	– Tensors para redes neurais: álgebra matricial essencial para redes neurais.
6.7	– Introdução a programação de redes neurais com o PyTorch.
6.8	– Long Short-Term Memory e Word Embedding com PyTorch.
6.9	– Como tornar seu modelo mais barato sem perder qualidade: model distillation. - "DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter", by Sanh et al.
6.10	– Benchmarks de LLM - GLUE, SuperGLUE, SQuAD, HELM, BIG-bench, entre outros. - Domain-specific benchmarks.
6.11	– LLMs e dados - Requisitos de dados para o treinamento de LLM. - Refinamento de LLMs com dados específicos de domínio. - Escalonamento de dados para o treinamento de LLMs. - Anotação e rotulagem de dados para o treinamento de LLMs. - O papel dos dados não rotulados no pré-treinamento de LLMs. - Aprendizado por transferência e reutilização de dados em LLMs.
6.12	– Onde vive o conhecimento em LLMs? Discussão sobre model interpretability e explainability.
6.13	– Os modelos de linguagem mais importantes
6.14	– Ética e LLMs - Bias and fairness. - Preocupações com privacidade. - Desinformação e misinformação. - Alucinações e confiabilidade. - Segurança e alinhamento.
6.15	– Local LLM: hardware - Requisitos de hardware para executar LLMs localmente. - Gerenciamento de memória e trade-offs no tamanho do modelo. - Tecnologias de aceleração de hardware (TPUs, CUDA, cuDNN ou oneAPI da Intel). - Marcas de GPU e desempenho: NVIDIA vs. AMD para LLMs. - Impacto da lei de Moore na implantação de LLMs locais.
6.16	– Local LLM on Edge Devices - Desafios de executar LLMs em dispositivos de borda. - Otimização de LLMs para dispositivos de borda. - Eficiência Energética de LLMs em dispositivos de borda. - Frameworks de IA para implantação de LLMs na borda (TensorFlow Lite, ONNX e PyTorch Mobile). - Inferência local vs. baseada na nuvem: prós e contras.
6.17	– Encadeamento de Pensamento (CoT) e Engenharia de Prompting - Prompting de poucos exemplos (Few-shot prompting). - Prompting sem exemplos (Zero-shot prompting). - Encadeamento de Pensamento (CoT prompting). - Prompting baseado em instruções.
6.18	– Sistemas Multiagentes e LLMs - Solução colaborativa de problemas com sistemas multiagentes e LLMs. - Protocolos de comunicação entre agentes usando LLMs. - Aprendizado pela Interação: aprendizado por reforço em sistemas multiagentes usando LLMs. - Sistemas multiagentes interdomínios com LLMs.

VI METODOLOGIA:

A disciplina será desenvolvida de forma interativa, envolvendo professor e alunos na perspectiva de integrar estudos teóricos através de atividades, tais como: aulas expositivas, discussões, trabalhos individuais e em grupos e as respectivas apresentações dos resultados desses trabalhos.

A avaliação do aluno será mediante trabalhos práticos com demonstração dos resultados obtidos e análise dos códigos desenvolvidos.

VII CRONOGRAMA DAS ATIVIDADES:

Semana	TURNO	PROGRAMA DE ATIVIDADES E DE ORIENTAÇÃO
1 – 5		Exposição do plano de curso, conteúdo programático, Unidade 1 e apresentação de trabalho sobre tópico
6 – 8		Unidade 2 e apresentação de trabalho sobre tópico
9 – 11		Unidade 3 e apresentação de trabalho sobre tópico
12 – 11		Unidade 4 e apresentação de trabalho sobre tópico
13 – 14		Unidade 5 e apresentação de trabalho sobre tópico
15 – 16		Apresentação dos trabalhos finais

VIII BIBLIOGRAFIA BÁSICA:

Livros:

- J. Starmer, *The StatQuest Illustrated Guide To Machine Learning*. Durham, NC: StatQuest, 2022.
- Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). Cambridge, MA: MIT Press.
- S. Raschka and V. Mirjalili, *Python Machine Learning: Machine Learning and Deep Learning with Python, scikit-learn, and TensorFlow 2*, 3rd ed. Birmingham, UK: Packt Publishing, 2019.
- A. Trask, *Grokking Deep Learning*. Shelter Island, NY: Manning Publications, 2019.
- I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA: MIT Press, 2016.
- S. Haykin, *Neural Networks and Learning Machines*. New York, NY: Prentice Hall, 2008.
- C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY: Springer, 2006.
- A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. Sebastopol, CA: O'Reilly Media, 2019.
- T. J. Sejnowski, *The Deep Learning Revolution*. Cambridge, MA: MIT Press, 2018.
- A. Burkov, *The Hundred-Page Machine Learning Book*. Victoria, BC: Andriy Burkov, 2019.
- D. Rothman, *Transformers for Natural Language Processing*. Birmingham, UK: Packt Publishing, 2021.
- Y. Goldberg, *Neural Network Methods for Natural Language Processing*. San Rafael, CA: Morgan & Claypool, 2017.

Artigos:

- Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278-2324, Nov. 1998.
- A. Krizhevsky, I. Sutskever, and G. E. Hinton, "ImageNet classification with deep convolutional neural networks," *Advances in Neural Information Processing Systems*, vol. 25, pp. 1097-1105, 2012.
- I. Sutskever, O. Vinyals, and Q. V. Le, "Sequence to sequence learning with neural networks," in *Advances in Neural Information Processing Systems*, vol. 27, pp. 3104-3112, 2014.
- A. Vaswani et al., "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017.

- A. Radford, K. Narasimhan, T. Salimans, and I. Sutskever, "Improving language understanding by generative pre-training," OpenAI, 2018.
- T. B. Brown et al., "Language models are few-shot learners," in *Advances in Neural Information Processing Systems*, vol. 33, pp. 1877-1901, 2020.
- J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)*, pp. 4171-4186, 2019.
- C. Raffel et al., "Exploring the limits of transfer learning with a unified text-to-text transformer," *Journal of Machine Learning Research*, vol. 21, pp. 1-67, 2020.
- J. Wei et al., "In-context learning and induction heads," *arXiv preprint arXiv:2209.11895*, 2022.